


Construção do Modelo: decisões técnicas e codificação

Bibliotecas utilizadas:


- Pandas;
- Numpy;
- Sclearn.

Base de dados para treinamento:

Limpamos os dados para que o modelo treinado possua maior precisão. O modelo legado cresceu consideravelmente em taxa de acerto após a limpeza dos dados destoantes: passou de um Erro Médio Absoluto (MAE) de 12 % para 6 %. Isso demonstra a importância do papel do engenheiro de dados.



Modelo legado antes do tratamento dos dados: MAE de ~12.5



Modelo legado após o tratamento dos dados: MAE de ~6.8

Para treinar o novo modelo, precisamos de uma base de dados confiável. Por isso, nosso primeiro passo é aplicar os conceitos de engenharia de dados, garantindo sua qualidade:

- Colapsar dados redundantes;
- Criar colunas que trazem novas informações;
- Tratar dados absurdos e outliers.

Decisões estratégicas:

Novas colunas:

- $df['c_med'] = (df['c_min'] + df['c_max'])/2$ (nova coluna `c_med` armazena a média dos valores `c_min` e `c_max`, duas variáveis altamente correlacionadas);
- $df['c_diff'] = df['c_max'] - df['c_min']$ (nova coluna `c_diff` armazena a diferença dos valores `c_min` e `c_max`);
- $df['progresso_sequencia'] = df['sequencia'] / df['sequenciatotal']$ = porcentagem de conclusão da sequência.

Colunas abandonadas:

- `c_min` e `c_max` apresentam informações redundantes e foram transformadas em outras métricas;
- 'qualidade' dando lugar às qualidades isoladas;
- 'acoatual' consideramos esta coluna redundante tendo em vista que possuímos as qualidades específicas de cada coluna;
- A coluna `corrida` foi abandonada, pois servia somente para armazenar o ID da corrida, informação irrelevante para análise.

- 'panela' foi abandonada, pois servia somente como identificador nominal para as painelas utilizadas.
-

Tradução de dados texto em tipos interpretáveis:

A coluna 'qualidade' carrega elementos do tipo string, que não podem ser analisados pela árvore de regressão. Portanto, devemos traduzir esses dados para algum tipo de valor numérico. Tendo em vista que o aço possui apenas uma qualidade, mapeamos a coluna com valores booleanos, em que o valor True designa a qualidade do material de determinada linha (run).

A coluna 'acoatual' também apresenta o mesmo problema. Verificamos a redundância entre essas colunas e descobrimos que a categoria de aço é dispensável para a análise, uma vez que carrega, essencialmente, a mesma informação que a qualidade, mas de maneira menos detalhada.

Para fazer isso, utilizamos a função `get_dummies()` da biblioteca pandas, ela transformou cada qualidade de aço em uma nova coluna e atribuiu a ela um valor verdadeiro ou falso.

Profundidade da árvore:

Representa o número máximo de decisões que a árvore pode fazer para chegar em uma predição. Por isso, será dado em função do número de variáveis analisadas, ou seja, da dimensão das colunas.

Teste de Modelos

Utilizamos 80% dos dados para treinar os modelos, enquanto 20% ficaram destinados para a validação do treinamento.

Modelo de árvore: árvore de regressão.

Nosso objetivo, encontrar uma otimização que supere aquela fornecida pelo modelo legado, representa um problema de regressão, pois trata da previsão de valores contínuos. Esse tipo de modelo exige um treinamento supervisionado, no qual são fornecidas as saídas corretas para um determinado número de entradas e, a partir de sua análise, são feitas predições.

Análise do modelo

O modelo de árvore de regressão é um dos mais simples modelos de árvores, utilizando somente uma dessas estruturas. Por isso, seu resultado não conseguiu superar o modelo legado, quando este teve seus dados tratados.

```
MAE da Árvore de Regressão: 7.999289267945985  
MAE do Modelo Legado: 6.764896395533493
```

```
MAE da Árvore de Regressão: 8.035966149506347  
MAE do Modelo Legado: 12.57792967028275
```

O aumento da profundidade da árvore de decisão não surtiu efeito na taxa de erro registrada acima.

Como melhorar esse modelo?

Random Forest:

Uma alternativa é repeti-lo diversas vezes de forma aleatória e calcular sua média. Este é o modelo chamado random forest, que cria diversas árvores de regressão, treina-as e calcula a média.

Com esse modelo, obtivemos um avanço, chegando a superar o modelo legado em 0.57 graus!


```
MAE do Modelo Legado: 6.76 °C  
MAE do Random Forest: 6.19 °C
```

XGBoost:

Aplicar o mesmo princípio de utilizar múltiplas análises em árvores de regressão. Entretanto, avalia agora o erro de cada repetição e atribui um peso a cada árvore, otimizando a solução. Ou seja, cada nova árvore é criada com o objetivo de suprir as deficiências da anterior. “Aprende com o erro” e evita o overfitting (decoreba) com o peso (coeficiente de aprendizado) aplicada a cada árvore.

MAE do Modelo Legado: 6.7649
MAE da Árvore de Regressão: 7.8301
MAE do XGBoost: 5.6569

Aqui o avanço já é bem mais expressivo: cerca de 1.11 graus!



LightGBM:

